T1 — Spot-Check Summary

Resumo estruturado dos experimentos de Spot-Checking

Identificação do grupo

Nome	Cartão UFRGS
Henrique Wermann da Silva	588786
João Kenji Suwa	587808
Otávio Rosa de Oliveira	588807

Link para o notebook do Google Colab (ou google drive com arquivos do T1):
https://colab.research.google.com/drive/17t-UYKRzLi7VB1VlsG92Sd-l76l9ze-r?usp=sharing

1. Definição do problema

Título do trabalho: Comparação de modelos para detecção de mensagens de Spam.

Dataset: https://www.kaggle.com/datasets/balaka18/email-spam-classification-dataset-csv

Variável alvo/problema a ser resolvido: Classificar e-mails em Spam ou Não-Spam.

Caracterização dos dados: 5172 instâncias, 3000 atributos, 2 classes (Spam e Não-Spam), sendo 1500 instâncias (29%) da classe Spam e 3672 (71%) Não-Spam

2. Preparação dos dados

Os atributos são a contagem de quantas vezes determinada palavra aparece em um e-mail. Considera-se a importância da palavra dentro do e-mail fazendo $tf(t,\ i) = 1 + log(contagem\ do\ termo\ na\ instância)$ para evitar superestimar a importância da palavra. Também é reduzido o peso de palavras que aparecem em diferentes emails com $idf(t) = log\,[\,(1 + total\ de\ instâncias) / (1 + instâncias\ com\ o\ termo)\,] + 1$, pois termos frequentes em muitas mensagens possuem menor capacidade de diferenciá-las.

O peso final é obtido por $tf(t,i)$ * $idf(t)$. Em seguida, é aplicada a normalização L2, dividindo cada peso pela raiz quadrada da soma dos quadrados dos pesos de todos os termos do e-mail, fazendo com que o comprimento dos textos tenha menor influência na representação.

Para evitar data-leakage, durante a validação cruzada, o IDF é calculado apenas sobre os dados de treinamento de cada fold e posteriormente aplicado aos dados de validação/teste.

O dataset não continha instâncias com dados ausentes ou amostras outliers (valores discrepantes ou atípicos), onde o dataset é composto apenas com dados reais e não sintéticos. Dessa forma, não foi aplicada nenhuma técnica para remoção ou tratamento de features.

3. Protocolo de avaliação

Tarefa	Classificação
Métrica principal	Precisão, pois no problema é muito importante não classificar emails normais como spam (falso-positivo)
Métricas avaliadas	Acurácia, Precisão, Recall e F1 Score
Particionamento dos dados	Holdout (20% Test split)
Estratégia de validação	K-fold cross validation estratificado com os 80% restantes. Foi utilizado um K = 5..
Tratamento do desbalanceamento de classes	Foi usado o stratify para manter as proporções das classes nos conjuntos de treino e teste.
Critério de comparação	Os modelos foram comparados pelas métricas apresentadas, principalmente a precisão.
Estratégias contra data leakage	Em cada fold da cross-validation, o IDF é calculado somente a partir dos dados de treinamento e posteriormente aplicado aos dados de validação.

4. Execução do Spot-Checking

Modelo	Configuração utilizada	Motivo da inclusão	Observações
Logistic Regression	max_iter=100, random_state=42	Incluído por ser um modelo linear simples e bom para classificações binárias.	Espera-se um bom desempenho por ser um modelo linear e adequado a problemas de classificação com muitas features.
Linear SVM	random_state=42	Incluído por ser um modelo linear adequado para classificação em casos com muitas amostras.	A característica do dataset de ser uma matriz esparsa favorece o desempenho deste modelo.
Decision Tree	random_state=42	Incluído por ser um modelo não linear capaz de representar relações mais complexas entre os atributos.	O modelo será utilizado em sua configuração padrão, então é esperado que isso impacte o desempenho.
XGBoost	objective="binary:logistic", tree_method="hist",	Incluído por ser um ensemble baseado em árvores,	Espera-se que o uso de múltiplas árvores permita melhor

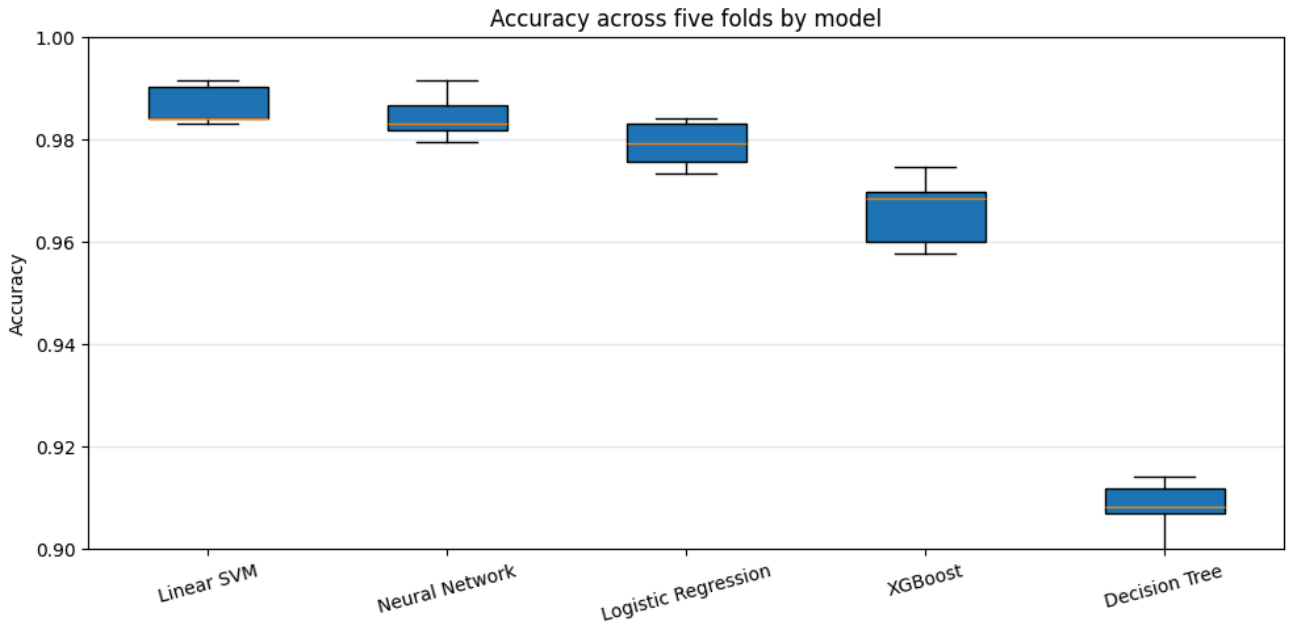
	random_state=42, n_jobs=1	podendo ser comparado com a Decision Tree.	desempenho que uma única árvore.
Neural network	hidden_layer_sizes=(100,), activation="relu", solver="adam", max_iter=500, random_state=42	Incluída para comparar uma abordagem baseada em redes neurais com os modelos tradicionais	Espera-se que o desempenho seja afetado pelo fato dos hiperparâmetros ainda não terem sido ajustados.

5. Resultados

5.1 Tabela comparativa

Modelo	**accuracy_mean**	**accuracy_std**	**f1_score_mean**	**f1_score_std**	**precision_mean**	**precision_std**	**recall_mean**	**recall_std**
Linear SVM	0.9867	0.0039	0.9772	0.0067	0.9736	0.0079	0.9808	0.0081
Neural Network	0.9845	0.0047	0.9735	0.0081	0.9664	0.0098	0.9808	0.0113
Logistic Regression	0.9792	0.0046	0.9641	0.0079	0.9659	0.0136	0.9625	0.0114
XGBoost	0.9662	0.0071	0.9425	0.0119	0.9289	0.0138	0.9567	0.0137
Decision Tree	0.9081	0.0056	0.8402	0.0102	0.8480	0.0074	0.8325	0.0130

5.2 Gráfico comparativo



6. Interpretação dos resultados

.

- **Quais modelos apresentaram resultados mais promissores segundo o protocolo definido?**

Linear SVM, Redes Neurais e Regressão Logística apresentaram os resultados mais promissores, destacando-se pela boa precisão e bom F1 score. As Redes Neurais surpreendem, pois apresentaram desempenho competitivo mesmo sem uma etapa de fine-tuning dos hiperparâmetros.

- **Quais padrões, diferenças ou comportamentos relevantes foram observados entre os modelos?**

Observou-se uma diferença clara entre os modelos lineares e os modelos baseados em árvores**.** A Linear SVM e a Regressão Logística apresentaram desempenho superior às árvores de decisão, enquanto os modelos de ensemble baseados em árvores também não conseguiram alcançar os melhores resultados. Esse comportamento sugere que a representação dos e-mails utilizada, baseada nas frequências das palavras, é mais adequada para modelos que conseguem trabalhar bem com uma grande quantidade de atributos esparsos.

- **O que os resultados sugerem sobre o problema e/ou sobre os dados?**

Os resultados apresentam desempenho consistente entre os diferentes folds, evidenciado pelo baixo desvio padrão dos testes, indicando que as divisões no conjunto de treinamento não provocaram grandes variações nas previsões. Isso sugere que o desempenho dos modelos não depende fortemente de uma divisão específica dos dados. Então, o bom desempenho dos classificadores indica que os atributos disponíveis contêm informações suficientes para distinguir Spam de Não-Spam, sugerindo a existência de padrões relevantes na frequência das palavras que podem ser explorados pelos modelos.

7. Seleção dos modelos para o T2

Os modelos que serão aprofundados na etapa dois serão a Rede Neural e a Árvore de Decisão, ambos pela possibilidade do aprofundamento. Embora a Neural Network já tenha obtido uma precisão de 0.9664 com desvio padrão de 0.0098, queremos descobrir o quanto o ajuste dos hiperparâmetros pode influenciar no desempenho. Já para as Decision Trees, queremos testar qual o impacto o ajuste de hiperparâmetros pode influenciar um modelo que primariamente se mostrou inadequado para o problema, com a Árvores de Decisão e o XGBoost tendo os piores desempenhos entre os modelos testados.

Uso de IA Generativa

O uso de IA foi feito primordialmente na construção de código e pipeline de treinamento apenas. A escrita do relatório, interpretação dos resultados, separação/preparação dos dados e a seleção dos modelos e métricas foram feitas pelos alunos de forma manual, sem qualquer uso de tecnologia externa. Todo código gerado foi analisado cuidadosamente e compreendido por todos.

Referências utilizadas

https://scikit-learn.org/stable/api/index.html - Site do scikit learn.

https://www.kaggle.com/datasets/balaka18/email-spam-classification-dataset-csv - Site do dataset SPAM