

Trabalho prático final - Parte 1 (T1)

Modelagem preditiva com Aprendizado de Máquina: Caracterização do problema e *spot-checking* de algoritmos

Contexto

Em Aprendizado de Máquina (AM), o *No-Free Lunch Theorem* estabelece que não há um único algoritmo com melhor desempenho universal, isto é, que seja o melhor algoritmo (e portanto, o recomendado) para todo e qualquer problema a ser resolvido. Assim, ao iniciar um novo projeto envolvendo o uso de algoritmos de aprendizado de máquina, recomenda-se explorar diferentes algoritmos no conjunto de dados para estabelecer um *baseline* de desempenho e escolher um subconjunto que pareça mais promissor para justificar uma investigação mais aprofundada.

A ideia de explorar rapidamente diferentes métodos de aprendizado de máquina é normalmente referida como "*spot-checking algorithms*" (em tradução livre, verificação pontual de algoritmos): o principal objetivo é obter um conjunto inicial de informações sobre os algoritmos que potencialmente serão melhores para o desenvolvimento de modelos preditivos para um conjunto de dados, determinando em quais deles vale a pena dedicar mais tempo à otimização de hiperparâmetros e à análise mais aprofundada dos modelos. Portanto, o *spot-checking* difere da otimização de um único algoritmo por meio do ajuste fino de seus hiperparâmetros. Podemos pensar no *spot-checking* como uma primeira etapa na escolha de algoritmos, que irá refinar o conjunto de algoritmos a serem explorados em mais profundidade na etapa de otimização de hiperparâmetros.

Neste processo de *spot-checking*, é sempre recomendado testar um conjunto diversificado de algoritmos, com diferentes tipos de viés indutivo, variando, por exemplo:

- o tipo de representação de hipóteses (e.g., árvores e instâncias)
- a estratégia de aprendizado (e.g., probabilística ou por otimização)
- o tipo de modelagem (e.g., linear ou não linear, paramétrica ou não paramétrica)

Assim, o Trabalho Prático - Parte 1 (**T1**) da disciplina **INF01017** visa permitir que os alunos iniciem a modelagem de um problema preditivo de interesse e desenvolvam um

pipeline para fazer um *spot-checking* de algoritmos de aprendizado supervisionado para a tarefa selecionada, seja de classificação ou de regressão.

Objetivo do Trabalho

A proposta deste trabalho prático é que os alunos realizem a **caracterização de um problema de modelagem preditiva** (classificação ou regressão) e **implementem e executem um *spot-checking* de algoritmos** para a tarefa escolhida

Organizados em **grupos de 2 ou 3 pessoas**, os alunos devem selecionar um problema de interesse, coletar dados, realizar uma análise exploratória dos dados, realizar um pré-processamento inicial, e comparar um conjunto diversificado de algoritmos de aprendizado de máquina para resolvê-lo. Esta comparação será realizada de acordo com a proposta de *spot-checking* de fornecer de forma rápida e objetiva um primeiro conjunto de resultados em um novo problema de modelagem preditiva.

Em linhas gerais, o processo de spot-checking envolve:

- Carregar os dados
- Realizar um pré-processamento inicial dos dados (ex.: normalização)
- Definir os algoritmos de aprendizado a serem aplicados
- Treinar e avaliar os modelos (utilizando valores padrão de hiperparâmetros ou variações mínimas)
- Sumarizar os resultados
- Apontar os algoritmos mais promissores

As seções a seguir detalham alguns aspectos do desenvolvimento do trabalho.

Desenvolvimento

Definição do problema e coleta de dados

Pode ser utilizado qualquer conjunto de dados de interesse do grupo que esteja relacionado a uma tarefa de classificação ou regressão. Como sugestão para os alunos, alguns repositórios que podem ser buscados:

PMLB : <https://epistasislab.github.io/pmlb/>

Kaggle: <https://www.kaggle.com/>

UCI ML Repository: <https://archive.ics.uci.edu/ml/datasets.php>

Solicita-se que, de preferência, os alunos utilizem conjuntos de dados que não tenham sido explorados ao longo da disciplina (por exemplo, em atividades práticas). A tarefa a ser abordada deve estar claramente descrita no relatório. Espera-se uma definição clara do objetivo do trabalho desenvolvido, ou seja, dos dados utilizados para

treinamento dos modelos e da pergunta de pesquisa que o grupo visou investigar com algoritmos de AM. Por exemplo: "Nosso trabalho tem como objetivo desenvolver um modelo baseado em AM para prever o tipo de vinho (tinto ou branco) a partir de um conjunto de características físico-químicas. Para tanto, utilizamos o conjunto de dados <breve descrição> disponível em <link para download>." ...

Para os trabalhos que envolverem dados publicamente disponíveis, os grupos devem incluir o link para download no seu relatório.

Análise exploratória dos dados (EDA, de *Exploratory Data Analysis*)

Realize uma análise exploratória dos dados coletados¹. O objetivo é entender melhor e sumarizar as características dos dados, analisando a quantidade e os tipos de atributos, verificando a distribuição do atributo alvo, identificando padrões e anomalias, removendo atributos que pareçam irrelevantes ou problemáticos, etc. Utilize gráficos e sumarizações estatísticas para a EDA. Verifique potenciais problemas nos dados, como por exemplo, a necessidade de normalizar os atributos, balancear classes, ou remover instâncias ou atributos por inconsistências nos dados. Inclua no seu relatório os resultados dessa análise e uma síntese dos eventuais problemas identificados.

Pré-processamento dos dados

Aplice técnicas de pré-processamento nos dados a fim de melhorar a qualidade dos mesmos por meio da eliminação ou minimização de problemas identificados na etapa anterior². A avaliação deste trabalho não exigirá um pré-processamento aprofundado, por ser um tópico ainda pouco discutido na disciplina, mas será esperado que os grupos lidem com aspectos como a remoção de atributos ou instâncias problemáticas (por exemplo, por conterem muitos valores faltantes ou não parecerem informativas para o problema), normalização de atributos, balanceamento de classes, transformação de atributos categóricos em numéricos, caso se mostrem necessários nos dados escolhidos.

As características dos dados usados, bem como as etapas envolvidas no pré-processamento dos dados, devem estar bem discutidas no relatório a ser entregue. Nos casos de não haver necessidade de pré-processar os dados, os grupos devem mencionar e justificar isto no texto.

¹ Leia o Capítulo **2** do livro base da disciplina “Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina”, para referência.

² Leia o Capítulo **3** do livro base da disciplina “Inteligência Artificial - Uma Abordagem de Aprendizado de Máquina”, para referência.

Definição da abordagem, dos algoritmos, e da estratégia de avaliação

Defina a abordagem de aprendizado de máquina que você planeja utilizar, isto é, se o problema é de classificação ou regressão. Justifique sua escolha com base na natureza do problema e nos dados disponíveis.

Selecione os algoritmos de aprendizado supervisionado a serem aplicados. Esta definição é de livre escolha do grupo, mas solicita-se que englobe algoritmos que constem no conteúdo programático da disciplina (podendo incluir de forma adicional outros algoritmos não abordados na disciplina). Além disso, sugere-se selecionar um conjunto diversificado de algoritmos quanto ao viés indutivo, com o propósito de spot-checking. Neste trabalho prático, os algoritmos podem ser aplicados com valores padrão de hiperparâmetros ou, se for a vontade do grupo, com variações mínimas neles (por exemplo, uma árvore de decisão sem poda e outra com poda não muito drástica). Os grupos devem comparar ao menos 5 algoritmos distintos.

Selecione as métricas de desempenho que serão usadas para avaliar os modelos a partir da definição da modelagem e da interpretação do problema a ser abordado. Neste processo, recomenda-se utilizar mais de uma métrica para avaliação e comparação de modelos, mas selecionar uma métrica como critério principal de seleção de modelos (ou seja, aquela que o grupo tentará otimizar na análise de desempenho dos algoritmos). Escolha, também, a estratégia que aplicará para realizar a divisão de dados para treinamento e avaliação (holdout, cross-validation, etc..)

No relatório, descreva as suas decisões a respeito da abordagem, dos algoritmos e das métricas de avaliação adotadas.

Spot-checking de algoritmos

Execute a verificação rápida dos algoritmos por meio do treinamento e da avaliação dos modelos, de acordo com as definições do item anterior. Testar uma variedade de algoritmos permite identificar quais modelos apresentam o melhor desempenho inicial com os dados disponíveis. Isso economiza tempo e esforço ao focar em algoritmos que de fato têm potencial para a tarefa em questão.

Recomenda-se a realização de múltiplas repetições do treinamento e da avaliação com cada algoritmo selecionado utilizando estratégias vistas em aula. É importante garantir a consistência dos resultados utilizando as mesmas divisões de dados em uma determinada iteração para todos os algoritmos. Também é recomendado utilizar a definição manual de *seeds* em processos aleatórios (parâmetro *random_state*, no scikit-learn), para fins de reprodutibilidade dos experimentos. Lembre-se de que, neste trabalho prático, não estamos interessados em realizar a otimização de hiperparâmetros ou a análise aprofundada dos modelos, como a interpretabilidade.

Descreva no relatório a sua estratégia de spot-checking, incluindo detalhes sobre como lidou com a divisão de dados e se executou repetições dos processos de treinamento e avaliação dos modelos.

Sumarização dos resultados

Faça a síntese dos resultados da avaliação dos modelos. O objetivo desta sumarização é identificar quais algoritmos se saíram melhor e merecem seguir para uma investigação mais detalhada, para uma escolha informada de algoritmos para a otimização de modelos. *Atenção: esta investigação está fora do escopo do T1.*

Para esta etapa, sugere-se o uso de sumarização por média e desvio padrão do desempenho, bem como gráficos do tipo box plot, violin plot, joy plot, etc, para visualização da distribuição de desempenho por modelo ao longo de n execuções. O uso de gráficos é importante pois viabiliza uma análise visual dos resultados.

Os grupos devem analisar os resultados, discutir de forma comparativa o desempenho dos modelos, e apontar as 3 estratégias mais promissoras para o problema em questão. Inclua no seu relatório esta discussão, com suporte em dados (tabelas e gráficos).

Ferramentas

Python é a linguagem recomendada por oferecer bibliotecas importantes, como o scikit-learn. Solicita-se o uso do Google Colab para fins de melhor reprodutibilidade do trabalho.

Entrega

Os grupos deverão enviar um relatório em PDF pelo Moodle, seguindo obrigatoriamente formato a ser disponibilizado pela professora, contendo:

- Identificação do grupo
- Um título significativo para o projeto (de acordo com o problema abordado).
- Link para o Notebook Google Colab, incluindo todas as etapas envolvidas no desenvolvimento do T1, do carregamento dos dados aos resultados do spot-checking e à seleção de modelos para o T2.
- Relato, na estrutura definida no template disponibilizado, das principais etapas do projeto:
 - preparação dos dados;

- definição do protocolo de avaliação;
 - execução do spot-checking;
 - resultados, com tabela e gráfico comparativo;
 - interpretação dos resultados;
 - seleção dos modelos para T2.
- O trabalho prático deverá ser apresentado oralmente pelo grupo, durante o período de aula, em data a ser determinada pela professora. Esta apresentação será realizada ao final do semestre, após realização e entrega do T2. A nota da apresentação será incorporada à avaliação do T2.
- Prazo de entrega: 25/10/2026, às 23:59h, via Moodle
 - Deve ser feita **uma entrega por grupo**

Critérios de avaliação

- Pontualidade na entrega do trabalho.
 - *Atenção:* atrasos na entrega do trabalho serão penalizados proporcionalmente ao tempo de atraso, sendo descontado 1 (um) ponto por dia de atraso (o T1 como um todo vale 10 pontos).
- Completude do trabalho e atendimento aos requisitos definidos neste enunciado.
- Qualidade e correção da metodologia para desenvolvimento e verificação rápida dos modelos, incluindo todas as etapas previstas neste enunciado.
- Qualidade do relatório final e da apresentação e discussão dos resultados, e abrangência em relação aos requisitos de relato definidos neste enunciado.

Dúvidas

Em caso de dúvidas sobre a realização do trabalho, incluindo a definição do tema de pesquisa, entre em contato com a professora através do e-mail mrmendoza@inf.ufrgs.br. Para dúvidas técnicas, sinta-se à vontade para usar o Fórum de Dúvidas no Moodle da disciplina.

Uso de Inteligência Artificial Generativa

O uso de ferramentas de Inteligência Artificial (IA) Generativa é permitido e incentivado como recurso complementar ao desenvolvimento do trabalho, podendo ser utilizado, por exemplo, para apoiar a compreensão de conceitos, explorar alternativas

metodológicas, revisar código, auxiliar na interpretação de resultados ou aprimorar a redação. Entretanto, a IA não deve substituir o processo de análise, tomada de decisão ou elaboração do trabalho pelos alunos. Todas as decisões metodológicas, escolhas de modelos, configurações experimentais, procedimentos de pré-processamento, métricas, interpretações e conclusões devem ser compreendidas e justificadas pelos integrantes do grupo. Os alunos devem ser capazes de explicar e defender integralmente o trabalho realizado, inclusive o código produzido ou modificado com auxílio de IA. O uso de IA não exime os alunos da responsabilidade pela correção, validade e reprodutibilidade dos resultados apresentados. Recomenda-se, ainda, que seu uso seja realizado de forma crítica, verificando as informações e códigos gerados antes de incorporá-los ao trabalho.