Trabalho prático final - Parte 2 (T2)
Modelagem preditiva com Aprendizado de Máquina: Otimização e interpretação de modelos

Contexto

O Trabalho Prático - Parte 1 (T1) da disciplina **INF01017** visou permitir uma experiência inicial na modelagem de um problema preditivo de interesse, seja de classificação ou de regressão, e o desenvolvimento de um pipeline para fazer um *spot-checking* de algoritmos de aprendizado supervisionado para a tarefa selecionada. De forma geral, o T1 envolveu a definição do problema a ser trabalhado, a coleta de dados, sua análise exploratória, definição da abordagem, métricas e métodos de avaliação e spot-checking, para avaliação preliminar e pontual de modelos. Isso permitiu o ganho de familiaridade com o problema selecionado e determinação de quais modelos podem ser explorados mais a fundo.

A proposta do **Trabalho Prático - Parte 2 (T2)** é exatamente realizar a análise mais aprofundada das estratégias mais promissoras encontradas em T1 e na comparação entre múltiplos modelos.

Objetivo do Trabalho

A proposta deste trabalho prático, em sua parte 2, é que os alunos otimizem um modelo para a tarefa escolhida, fazendo uma análise aprofundada de ajuste de hiperparâmetros e avaliação de desempenho com as estratégias mais promissoras identificadas na parte 1 do projeto.

Organizados no mesmo grupo (de até 3 pessoas), os alunos devem tentar chegar ao melhor desempenho possível para o problema escolhido com base nos 2-3 algoritmos mais promissores apontados em T1. Os alunos deverão concluir o pipeline de modelagem preditiva com AM, explorando, analisando e discutindo em maiores detalhes o desempenho dos modelos treinados e fazendo uma análise de interpretabilidade para um modelo escolhido.

Desenvolvimento

Otimização de hiperparâmetros

Cada algoritmo escolhido como resultado do T1 deve ser treinado para obter o melhor desempenho possível. Não havendo um referencial de desempenho para o problema, os grupos devem reportar o melhor modelo dentre todos os que foram treinados e avaliados. Isso envolve o melhor ajuste de hiperparâmetros que for possível encontrar. Automatizar essa etapa de otimização de hiperparâmetros pode economizar bastante esforço. O scikit-learn oferece o GridSearch que é uma busca exaustiva trivial. Assim, bibliotecas que implementam algoritmos mais "inteligentes", como Hyperopt e Optuna, podem ser um diferencial na obtenção de um bom desempenho.

Os grupos devem garantir que a metodologia de pré-processamento, treino e validação esteja correta. Um aspecto particularmente crítico é a prevenção de *data leakage* (ie, vazamento de dados), que pode comprometer os resultados e a validade do modelo. Por exemplo, o cálculo das estatísticas de pré-processamento (e.g. fit do scikit-learn para normalização, balanceamento de dados e imputação) só pode ser feito nos dados de treino. Esse cálculo é, então, aplicado (e.g. transform do scikit-learn) nos dados de treino, validação e teste. Além disso, a otimização de hiperparâmetros deve ser avaliada no conjunto de validação e não no de teste.

A divisão dos dados em treino, validação e teste pode ser feita via holdout de 3-vias ou holdout+validação cruzada (CV), onde o holdout separa o de teste e o restante é dividido conforme a validação cruzada, ou validação cruzada (CV) aninhada. Os grupos devem avaliar qual a melhor estratégia, balanceando a confiabilidade do método (e.g. validação cruzada aninhada garante mais variabilidade nos dados) vs o tempo de execução (e.g. 5-folds externos e 3-folds internos de CV aninhada fazem com que cada possível modelo seja treinado e avaliado 15 vezes). Independentemente do método escolhido, a divisão dos dados deve ser estratificada (e.g. mesmo percentual de cada classe no treino, validação e teste).

Avaliação de desempenho

Utilizem as métricas definidas na primeira parte do trabalho para comparar os modelos, garantindo que a métrica seja a correta para o problema, considerando eventuais desbalanceamentos nos dados.

Após a otimização de hiperparâmetros de todos os modelos candidatos (isto é, aqueles treinados com 2-3 estratégias mais promissoras escolhidas com base em T1), o desempenho dos modelos nos dados de teste deve ser comparado para identificar qual modelo oferece o melhor desempenho global e quais são os pontos fortes e fracos de

cada modelo. Com base nesta análise, os grupos devem tentar definir o modelo mais indicado para atacar o problema abordado.

Criem gráficos e visualizações que ajudem a ilustrar as comparações entre os modelos. Conforme apropriado, obtenham curvas ROC ou PR, gráficos de barras comparando as métricas de cada modelo, e/ou matrizes de confusão.

Identifiquem o melhor modelo, ou se não há um modelo claramente melhor, quais são os "vencedores" e as situações e características de vantagem e desvantagem entre eles. Verifiquem os casos (instâncias/amostras) onde o melhor modelo (ou os melhores, em caso de "empate") vai(vão) bem ou mal. A análise não deve ser pra cada amostra individual, mas de maneira agregada. Por exemplo, se o problema for de classificação, analise qual é a classe mais difícil para o modelo, e se há amostras "confusas" no sentido que seus atributos parecem realmente pertencer a outra classe. Se o problema é de regressão, veja se há algum padrão onde os erros são maiores.

Interpretação do modelo final

Os alunos deverão explorar algum método de interpretação de modelos e/ou modelos naturalmente interpretáveis (por exemplo, árvores de decisão), a fim de compreender ou extrair hipóteses sobre quais atributos são aparentemente mais relevantes para a tarefa de predição e/ou como eles impactam na decisão do modelo. Sugere-se que se faça esta investigação apenas para um modelo, a ser escolhido com base no melhor desempenho preditivo em dados de teste (isto é, o melhor modelo conforme análise do grupo). Os grupos deverão incluir no relatório informações obtidas desta análise, como gráficos, tabelas, etc, e discutir a respeito das relações encontradas na análise que mais chamaram a atenção, seja pela pertinência da associação ou por ser um resultado inesperado.

Entrega

Os grupos deverão enviar um **documento em PDF** pelo Moodle, seguindo a estrutura de **Model Cards,** disponibilizada pela professora no Moodle[1]. O uso deste formato é obrigatório. O documento conterá a identificação do grupo, principais informações sobre o desenvolvimento do modelo e resultados obtidos, e o link para o notebook ou repositório.

[1] Inspirado no artigo *Model Cards for Model Reporting* - https://arxiv.org/abs/1810.03993

O trabalho prático deverá ser apresentado oralmente pelo grupo, durante o período de aula, em data a ser determinada pela professora.

- Prazo de entrega: 29/11/2026, às 23:59h, via Moodle
    - Deve ser feita **uma entrega por grupo**

Critérios de avaliação

- Pontualidade na entrega do trabalho.
    - *Atenção*: atrasos na entrega do trabalho serão penalizados proporcionalmente ao tempo de atraso, sendo descontado 1 (um) ponto por dia de atraso (o T1 como um todo vale 10 pontos).
- Completude do trabalho e atendimento aos requisitos definidos neste enunciado.
- Qualidade e corretude da metodologia para otimização, avaliação e interpretação dos modelos.
- Qualidade do relatório final em termos da estrutura, da redação e da discussão dos itens pedidos no enunciado.
- Apresentação oral do trabalho (valendo 20% da nota de T2)

Dúvidas

Em caso de dúvidas sobre a realização do trabalho, incluindo a definição do tema de pesquisa, entre em contato com a professora através do e-mail mrmendoza@inf.ufrgs.br. Para dúvidas técnicas, sinta-se à vontade para usar o Fórum de Dúvidas no Moodle da disciplina.

Uso de Inteligência Artificial Generativa

O uso de ferramentas de Inteligência Artificial (IA) Generativa é permitido e incentivado como recurso complementar ao desenvolvimento do trabalho, podendo ser utilizado, por exemplo, para apoiar a compreensão de conceitos, explorar alternativas metodológicas, revisar código, auxiliar na interpretação de resultados ou aprimorar a redação. Entretanto, a IA não deve substituir o processo de análise, tomada de decisão ou elaboração do trabalho pelos alunos. Todas as decisões metodológicas, escolhas de modelos, configurações experimentais, procedimentos de pré-processamento, métricas, interpretações e conclusões devem ser compreendidas e justificadas pelos integrantes

do grupo. Os alunos devem ser capazes de explicar e defender integralmente o trabalho realizado, inclusive o código produzido ou modificado com auxílio de IA. O uso de IA não exime os alunos da responsabilidade pela correção, validade e reprodutibilidade dos resultados apresentados. Recomenda-se, ainda, que seu uso seja realizado de forma crítica, verificando as informações e códigos gerados antes de incorporá-los ao trabalho.